

Métodos de Otimização em Contexto Industrial

Otimização não linear com restrições

Condições de otimalidade - problemas com restrições de igualdade

Método da Programação Quadrática Sequencial

Ana Maria A. C. Rocha

Departamento de Produção e Sistemas

Universidade do Minho

arocha@dps.uminho.pt

Ano letivo 2023/24

Problemas com restrições

1. Problema com restrições de limites simples:

$$\begin{aligned} x^* = & \arg \min_{x \in \mathbb{R}^n} f(x) \\ \text{sujeito a} & \quad l_i \leq x_i \leq u_i, \quad i = 1, \dots, n \end{aligned}$$

2. Problema com restrições de igualdade:

$$\begin{aligned} x^* = & \arg \min_{x \in \mathbb{R}^n} f(x) \\ \text{sujeito a} & \quad c_i(x) = 0, \quad i = 1, \dots, m \end{aligned} \tag{1}$$

3. Problema com restrições de desigualdade (menor ou igual):

$$\begin{aligned} x^* = & \arg \min_{x \in \mathbb{R}^n} f(x) \\ \text{sujeito a} & \quad h_j(x) \leq 0, \quad j = 1, \dots, p \end{aligned} \tag{2}$$

x^* é a solução do problema com restrições.

A formulação geral

$$\begin{array}{ll} \min_{x \in \mathbb{R}^n} & f(x) \\ \text{sujeito a} & c_i(x) = 0, \quad i = 1, \dots, m \\ & h_j(x) \leq 0, \quad j = 1, \dots, p \\ & l_i \leq x_i \leq u_i, \quad i = 1, \dots, n \end{array} \quad (3)$$

Restrições de igualdade

$$c(x) = 0, \quad c : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

Restrições de desigualdade (menor ou igual)

$$h(x) \leq 0, \quad h : \mathbb{R}^n \rightarrow \mathbb{R}^p$$

Restrições de limites simples

$$l \leq x \leq u, \quad l, u \in \mathbb{R}^n$$

Ponto admissível

Os pontos $x \in \mathbb{R}^n$ que verificam **todas as restrições** do problema formam a **região admissível**:

$$\mathbf{A} = \{x : c(x) = 0, h(x) \leq 0, l \leq x \leq u\} \subseteq \mathbb{R}^n$$

Um ponto $x \in \mathbf{A}$ (que verifica as restrições) diz-se **ponto admissível**.

A solução do problema tem de ser um ponto admissível.

Num problema de minimização com restrições, pretende-se calcular

$$x^* \in \mathbf{A} \leftarrow \text{minimizante} : f(x^*) \leq f(x) \text{ para todo o } x \in \mathbf{A}.$$

Num problema de maximização pretende-se calcular

$$x^* \in \mathbf{A} \leftarrow \text{maximizante} : f(x^*) \geq f(x) \text{ para todo o } x \in \mathbf{A}.$$

Problema com restrições de igualdade

$$\begin{array}{ll} \min_{x \in \mathbb{R}^n} & f(x) \\ \text{sujeito a} & c(x) = 0 \end{array} \quad (4)$$

com alguma das funções $f(x)$ e/ou $c(x)$ não linear em x .

- função objetivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$
- funções das restrições $c : \mathbb{R}^n \rightarrow \mathbb{R}^m$

$$c(x) = \begin{pmatrix} c_1(x) \\ c_2(x) \\ \vdots \\ c_m(x) \end{pmatrix}$$

- $n \Leftrightarrow$ número de variáveis do problema
- $m \Leftrightarrow$ número de restrições de igualdade

Exemplo

$$\begin{array}{ll}\min_{x \in \mathbb{R}^5} & e^{x_1 x_2 x_3 x_4 x_5} \\ \text{s.a} & x_1^2 + x_2^2 + x_3^2 + x_4^2 + x_5^2 = 10 \\ & x_2 x_3 = 5 x_4 x_5 \\ & x_1^3 + x_2^3 = -1\end{array}$$

$$\underbrace{x_1^2 + x_2^2 + x_3^2 + x_4^2 + x_5^2 - 10}_{c_1(x)} = 0$$
$$\underbrace{x_2 x_3 - 5 x_4 x_5}_{c_2(x)} = 0$$
$$\underbrace{x_1^3 + x_2^3 + 1}_{c_3(x)} = 0$$

Gradiente de $f(x)$

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$$

vetor de n elementos

Hessiana de $f(x)$

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \vdots & \cdots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix}$$

matriz simétrica de $n \times n$

Gradientes das restrições $c_i(x)$ $(i = 1, \dots, m)$

$$\begin{array}{l} \nabla c_1(x) = \begin{pmatrix} \frac{\partial c_1}{\partial x_1} \\ \vdots \\ \frac{\partial c_1}{\partial x_n} \end{pmatrix} \Leftrightarrow \text{vetor de } n \text{ elementos} \\ \vdots \\ \nabla c_m(x) = \begin{pmatrix} \frac{\partial c_m}{\partial x_1} \\ \vdots \\ \frac{\partial c_m}{\partial x_n} \end{pmatrix} \Leftrightarrow \text{vetor de } n \text{ elementos} \end{array}$$

Existem m gradientes das restrições.

Matriz que contém os gradientes das restrições ao longo das colunas

$$\nabla c(x) = \begin{pmatrix} \frac{\partial c_1}{\partial x_1} & \cdots & \frac{\partial c_m}{\partial x_1} \\ \vdots & \cdots & \vdots \\ \frac{\partial c_1}{\partial x_n} & \cdots & \frac{\partial c_m}{\partial x_n} \end{pmatrix}$$

$$\nabla c(x) \in \mathbb{R}^{n \times m} \text{ (matriz de ordem } n \times m \text{)}$$

$$\nabla c(x) = \left(\nabla c_1(x) \quad \nabla c_2(x) \quad \cdots \quad \nabla c_m(x) \right)$$

Hessianas das restrições $c_i(x)$ ($i = 1, \dots, m$)

$$\nabla^2 c_1(x) = \begin{pmatrix} \frac{\partial^2 c_1}{\partial x_1^2} & \cdots & \frac{\partial^2 c_1}{\partial x_n \partial x_1} \\ \vdots & \cdots & \vdots \\ \frac{\partial^2 c_1}{\partial x_1 \partial x_n} & \cdots & \frac{\partial^2 c_1}{\partial x_n^2} \end{pmatrix} \in \mathbb{R}^{n \times n} \Leftrightarrow \text{matriz simétrica } n \times n$$

$\vdots$

$$\nabla^2 c_m(x) = \begin{pmatrix} \frac{\partial^2 c_m}{\partial x_1^2} & \cdots & \frac{\partial^2 c_m}{\partial x_n \partial x_1} \\ \vdots & \cdots & \vdots \\ \frac{\partial^2 c_m}{\partial x_1 \partial x_n} & \cdots & \frac{\partial^2 c_m}{\partial x_n^2} \end{pmatrix} \in \mathbb{R}^{n \times n} \Leftrightarrow \text{matriz simétrica } n \times n$$

Existem m Hessianas das restrições.

Função Lagrangeana

Seja $L(x, \lambda)$ a **função Lagrangeana** associada ao problema e definida por

$$\begin{aligned} L(x, \lambda) &= f(x) - \lambda^T c(x) \\ &= f(x) - \sum_{i=1}^m \lambda_i c_i(x) \end{aligned}$$

em que

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, \quad \lambda = \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_m \end{pmatrix}$$

λ é o vetor dos multiplicadores de Lagrange associado às restrições de igualdade

Condição de regularidade

Seja x^* uma solução do problema (4).


Se os vetores

$$\nabla c_1(x^*), \nabla c_2(x^*), \dots, \nabla c_m(x^*)$$

(gradientes das restrições, calculados na solução)

forem linearmente independentes, então x^* é ponto regular.

Problema com 2 restrições de igualdade



- 2 pontos regulares
- 1 ponto não regular

Exemplo de aplicação – 1

$$\begin{array}{ll}\min_{x \in \mathbb{R}^3} & f(x) \\ \text{s.a} & x_1^2 + x_2^2 + x_3^2 = 3 \\ & 2x_1 - 4x_2 + x_3^2 = -1\end{array}$$

Verifique se o ponto $x^* = (1, 1, 1)^T$ é admissível e regular.

Verificar se x^* é admissível

$$\begin{cases} c_1(x) = x_1^2 + x_2^2 + x_3^2 - 3 = 0 \\ c_2(x) = 2x_1 - 4x_2 + x_3^2 + 1 = 0 \end{cases} \quad \begin{cases} 0 = 0 & \text{Verdadeiro} \\ 0 = 0 & \text{Verdadeiro} \end{cases}$$

Verificar se x^* é ponto regular

$$\begin{cases} \nabla c_1(x) = (2x_1, 2x_2, 2x_3)^T \\ \nabla c_2(x) = (2, -4, 2x_3)^T \end{cases} \quad \begin{cases} \nabla c_1(x^*) = (2, 2, 2)^T \\ \nabla c_2(x^*) = (2, -4, 2)^T \end{cases}$$

$\nabla c_1(x^*)$ e $\nabla c_2(x^*)$ são linearmente independentes

Então $x^* = (1, 1, 1)^T$ é admissível e regular.

Condições necessárias (e suficientes) de 1ª ordem

Condições KKT

Seja x^* uma solução do problema (4).

Se x^* é **ponto regular** então existe **um** λ^* que satisfaz

$$\begin{cases} \nabla_x L(x^*, \lambda^*) \equiv \nabla f(x^*) - \nabla c(x^*) \lambda^* = 0 \implies n \text{ equações} \\ \nabla_\lambda L(x^*, \lambda^*) \equiv -c(x^*) = 0 \implies m \text{ equações} \end{cases}$$



Este sistema de $n + m$ equações é não linear em x e define as condições **Karush-Kuhn-Tucker (KKT)**.

Ponto KKT

(x^*, λ^*) é **ponto estacionário** da Lagrangeana e chama-se ponto (ou par) **KKT**.

Interpretação das condições KKT

$$1. \nabla_{\lambda} L(x^*, \lambda^*) = 0$$

$$\nabla_{\lambda} L(x^*, \lambda^*) \equiv -c(x^*) = 0$$

o ponto verifica as restrições, ou seja, x^* é **ponto admissível**

$$2. \nabla_x L(x^*, \lambda^*) = 0$$

$$\nabla_x L(x^*, \lambda^*) \equiv \nabla f(x^*) - \nabla c(x^*) \lambda^* = 0$$


$$\Leftrightarrow \nabla f(x^*) = \nabla c(x^*) \lambda^*$$

$$\Leftrightarrow \nabla f(x^*) = \sum_{i=1}^m \lambda_i^* \nabla c_i(x^*)$$

em x^* , o gradiente de f é uma combinação linear dos gradientes das restrições


Exemplos

$$\min f(x) \text{ (linear) s.a} \\ h(x) \equiv x_1^2 + x_2^2 - 2 = 0$$



$(-1, -1)$ é KKT



$$\min f(x) \text{ (linear) s.a} \\ h_1(x) \equiv (x_1 - 1)^2 + x_2^2 - 1 = 0 \\ h_2(x) \equiv (x_1 - 2)^2 + x_2^2 - 4 = 0$$



$(0, 0)$ não é KKT

Exercício 1

$$\begin{aligned} \min \quad & f(x) \equiv 3x_1 - 4x_2 \\ \text{s.a} \quad & c_1(x) \equiv (x_1 + 1)^2 + x_2^2 - 1 = 0 \\ & c_2(x) \equiv (x_1 - 1)^2 + x_2^2 - 1 = 0 \end{aligned}$$



Calcule os pontos admissíveis. Verifique se são regulares.

Resolução do Exercício 1

1) Calcular os pontos admissíveis do problema:

Ponto que verifica $c_1(x) = 0$ e $c_2(x) = 0$.

$$\begin{cases} (x_1 + 1)^2 + x_2^2 - 1 = 0 \\ (x_1 - 1)^2 + x_2^2 - 1 = 0 \end{cases} \Leftrightarrow \begin{cases} x_2^2 - 1 = -(x_1 + 1)^2 \\ (x_1 - 1)^2 - (x_1 + 1)^2 = 0 \end{cases} \Leftrightarrow$$

$$\Leftrightarrow \begin{cases} x_2^2 - 1 = -1 \\ x_1 = 0 \end{cases} \Leftrightarrow \begin{cases} x_2 = 0 \\ x_1 = 0 \end{cases} \Rightarrow x^* = (0, 0)^T \text{ é ponto admissível}$$

2) Verificar se o ponto é regular

$$\nabla c_1(x) = \begin{pmatrix} 2(x_1 + 1) \\ 2x_2 \end{pmatrix} \text{ e } \nabla c_2(x) = \begin{pmatrix} 2(x_1 - 1) \\ 2x_2 \end{pmatrix}$$

$$\nabla c_1(x^*) = \begin{pmatrix} 2 \\ 0 \end{pmatrix} \text{ e } \nabla c_2(x^*) = \begin{pmatrix} -2 \\ 0 \end{pmatrix}$$

$$\text{Como } \exists \text{ um } \alpha : \begin{pmatrix} 2 \\ 0 \end{pmatrix} = \alpha \begin{pmatrix} -2 \\ 0 \end{pmatrix} \Leftrightarrow \alpha = -1$$

$\Rightarrow$ os gradientes das restrições em x^* são linearmente dependentes, logo o ponto $(0, 0)$ não é regular $\Leftrightarrow$ a condição de regularidade não é verificada.

Condições necessárias de 2ª ordem

Seja x^* uma solução do problema (4).

Se x^* é ponto regular que satisfaz as condições KKT, então para todos os vetores $s \in \mathbb{R}^n$ que verificam

$$\nabla c(x^*)^T s = 0$$

(vetores tangentes às curvas admissíveis) tem-se

$$s^T \nabla_{xx}^2 L(x^*, \lambda^*) s \geq 0.$$

Nota:

A matriz Hessiana da função Lagrangeana, em ordem a x , é

$$\nabla_{xx}^2 L(x, \lambda) = \nabla^2 f(x) - \sum_{i=1}^m \lambda_i \nabla^2 c_i(x)$$

Condições suficientes de 2ª ordem

Se (x^*, λ^*) é um par KKT, isto é,

$$\begin{cases} \nabla_x L(x^*, \lambda^*) = 0 \\ \nabla_\lambda L(x^*, \lambda^*) = 0 \end{cases}$$

e se

$$s^T \nabla_{xx}^2 L(x^*, \lambda^*) s > 0$$

para todo o s ($s \neq 0$) tal que

$$\nabla c(x^*)^T s = 0,$$

então x^* é minimizante local forte.

Condições suficientes de 2ª ordem

No entanto, se (x^*, λ^*) é um par KKT, isto é,

$$\begin{cases} \nabla_x L(x^*, \lambda^*) = 0 \\ \nabla_\lambda L(x^*, \lambda^*) = 0 \end{cases}$$

e se

$$s^T \nabla_{xx}^2 L(x^*, \lambda^*) s < 0$$

para todo o s ($s \neq 0$) tal que

$$\nabla c(x^*)^T s = 0$$


então x^* é maximizante local forte.

Exercício 2

Usando as condições de otimalidade, calcule uma solução (minimizante) de

$$\begin{array}{ll} \min_{x \in \mathbb{R}^2} & f(x) \equiv 2(x_1^2 + x_2^2 - 1) - x_1 \\ \text{s.a} & c(x) \equiv x_1^2 + x_2^2 - 1 = 0 \end{array}$$

- 1 Defina o sistema das condições **KKT**. Verifique se o ponto $x^* = (1, 0)^T$ e $\lambda^* = \frac{3}{2}$ é ponto estacionário da função Lagrangeana.
- 2 Verifique se o ponto é regular.
- 3 Verifique as condições suficientes de 2ª ordem.
- 4 A função f tem um maximizante? Qual?



Resolução do Exercício 2

Função Lagrangeana associada ao problema:

$$L(x, \lambda) = 2x_1^2 + 2x_2^2 - x_1 - 2 - \lambda (x_1^2 + x_2^2 - 1)$$

1) Pontos estacionários da Lagrangeana:

$$\begin{cases} \nabla_x L(x, \lambda) = 0 \\ \nabla_\lambda L(x, \lambda) = 0 \end{cases} \Leftrightarrow \begin{cases} \nabla_x L(x, \lambda) = \nabla f(x) - \nabla c(x) \lambda = 0 \\ \nabla_\lambda L(x, \lambda) = c(x) = 0 \end{cases}$$

Sabendo que $\nabla f(x) = \begin{pmatrix} 4x_1 - 1 \\ 4x_2 \end{pmatrix}$ e que $\nabla c(x) = \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix}$ então

$$\nabla_x L(x, \lambda) = \begin{pmatrix} 4x_1 - 1 \\ 4x_2 \end{pmatrix} - \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix} \lambda = \begin{pmatrix} 4x_1 - 1 - 2x_1\lambda \\ 4x_2 - 2x_2\lambda \end{pmatrix} = 0$$

$$\nabla_\lambda L(x, \lambda) = x_1^2 + x_2^2 - 1 = 0,$$

logo o sistema a resolver é dado por $\begin{cases} 4x_1 - 1 - 2x_1\lambda = 0 \\ 4x_2 - 2x_2\lambda = 0 \\ x_1^2 + x_2^2 - 1 = 0 \end{cases}$

Usando $x^* = (1, 0)^T$ e $\lambda^* = \frac{3}{2}$, o sistema fica

$$\begin{cases} 4 - 1 - 3 = 0 \\ 0 - 0 = 0 \\ 1 + 0 - 1 = 0 \end{cases} \Leftrightarrow \begin{cases} 0 = 0 \\ 0 = 0 \\ 0 = 0 \end{cases} \Rightarrow x^* \text{ é ponto admissível}$$

Então (x^*, λ^*) é par KKT, ou seja, é ponto estacionário da Lagrangeana.

Resolução do Exercício 2 (cont.)

2) Será que o ponto $x^* = (1, 0)^T$ é regular?

Os gradientes das restrições em x^* terão de formar um conjunto de vetores linearmente independentes para x^* ser regular.

Como $m = 1 \Rightarrow \nabla c(x^*) = \begin{pmatrix} 2 \\ 0 \end{pmatrix}$ é linearmente independente.

$\left. \begin{array}{l} x^* \text{ é ponto admissível} \\ (x^*, \lambda^*) \text{ é par KKT} \\ x^* \text{ é ponto regular} \end{array} \right\} \Rightarrow \begin{array}{l} \text{as condições de otimalidade de} \\ \text{1ª ordem verificam-se em } (x^*, \lambda^*). \end{array}$

3) Será que $x^* = (1, 0)^T$ é minimizante?

Vamos verificar a condição suficiente de 2ª ordem:

Se (x^*, λ^*) é par KKT e se $s^T \nabla_{xx}^2 L(x^*, \lambda^*) s > 0$ para todo o $s (\neq 0) \in \mathbb{R}^2 : \nabla c(x^*)^T s = 0 \Rightarrow x^*$ é minimizante.

$$\nabla c(x^*)^T s = (2 \ 0) \begin{pmatrix} s_1 \\ s_2 \end{pmatrix} = 0 \Leftrightarrow 2s_1 + 0s_2 = 0 \Rightarrow \begin{cases} s_1 = 0 \\ s_2 \text{ é qualquer} \end{cases}$$

Resolução do Exercício 2 (cont.)

$$\text{Então } s = \begin{pmatrix} 0 \\ s_2 \end{pmatrix} \forall s_2.$$

$$\nabla_{xx}^2 L(x, \lambda) = \nabla^2 f(x) - \sum_{i=1}^m \lambda_i \nabla^2 c_i(x)$$

$$\text{Como } m = 1, \nabla^2 f(x) = \begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix} \text{ e } \nabla^2 c(x) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}, \text{ então}$$

$$\nabla_{xx}^2 L(x^*, \lambda^*) = \begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix} - \frac{3}{2} \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$\text{Assim, } s^T \nabla_{xx}^2 L(x^*, \lambda^*) s = (0 \ s_2) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ s_2 \end{pmatrix} = s_2^2$$

Como para qualquer $s_2 (\neq 0)$ temos que $s_2^2 > 0 \Rightarrow x^*$ é minimizante.

4) A função f tem um maximizante? Qual?

Como o problema só tem um ponto estacionário da Lagrangeana, e esse ponto é minimizante, então a função não tem maximizantes.

Método da Programação Quadrática Sequencial

O Método da Programação Quadrática Sequencial (ou Sequential Quadratic Programming (SQP), em inglês) é talvez o mais conhecido para resolver um problema de otimização não linear com todo o tipo de restrições (igualdades, desigualdades e limites simples).

Para simplificar, apenas se descreve o método SQP quando aplicado a um problema com restrições de igualdade

$$\begin{array}{ll} \min_{x \in \mathbb{R}^n} & f(x) \\ \text{s.a} & c(x) = 0 \end{array} \quad (5)$$

com $c(x) = (c_1(x), \dots, c_m(x))^T$.

Método da Programação Quadrática Sequencial

O método aproxima localmente o problema (5) por um problema mais simples de programação quadrática. Assim

- a função objetivo $f(x)$ é aproximada por um modelo quadrático
- as funções das restrições $c(x)$ são aproximadas por modelos lineares.

Seja $x^{(k)}$ uma aproximação à solução do problema (5).

Da expansão em série de Taylor de $f(x)$, no ponto $x^{(k)} + d$

$$f(x^{(k)} + d) = f(x^{(k)}) + d^T \nabla f(x^{(k)}) + \frac{1}{2} d^T \nabla^2 f(x^{(k)}) d + \dots,$$

os três primeiros termos definem um modelo quadrático em d .

$$\begin{aligned} f(x^{(k)} + d) &\approx f(x^{(k)}) + d^T \nabla f(x^{(k)}) + \frac{1}{2} d^T \nabla^2 f(x^{(k)}) d \\ &= q(d). \end{aligned}$$

Da mesma forma, da expansão em série de Taylor da função $c(x)$, no ponto $x^{(k)} + d$

$$c(x^{(k)} + d) = c(x^{(k)}) + \nabla c(x^{(k)})^T d + \dots$$

obtém-se um modelo linear em d

$$c(x^{(k)} + d) \approx c(x^{(k)}) + \nabla c(x^{(k)})^T d = l(d).$$

Método da Programação Quadrática Sequencial

O problema (5) vai ser aproximado por um problema de programação quadrática:

$$\begin{array}{ll}\min_{d \in \mathbb{R}^n} & q(d) \\ \text{s.a} & l(d) = 0\end{array}$$



$$\begin{array}{ll}\min_{d \in \mathbb{R}^n} & d^T \nabla f(x^{(k)}) + \frac{1}{2} d^T \nabla^2 f(x^{(k)}) d \\ \text{s.a} & c(x^{(k)}) + \nabla c(x^{(k)})^T d = 0\end{array} \quad (6)$$

- cuja solução é um vetor $d^{(k)}$, conhecido por **direção de procura**;
- como a aproximação de $f(x)$ por um modelo quadrático $q(d)$ é válida numa pequena vizinhança de $x^{(k)}$, a solução de (6) – $d^{(k)}$ – vai originar uma nova aproximação à solução de (5)

$$x^{(k)} + d^{(k)} \curvearrowright x^{(k+1)}$$

e não, já, a sua solução x^* ;

- o processo tem de ser repetido com base na nova aproximação $x^{(k+1)}$.

★ SQP é um método iterativo que resolve em cada iteração, k , um problema de **Programação Quadrática**.

- ▶ A solução do **problema quadrático** fornece a direção de procura com a qual se calcula a nova aproximação.
- ▶ O processo termina quando a aproximação estiver perto da solução do problema (5).
- ▶ Esta proximidade é verificada pelas condições KKT.

Hessiana do problema quadrático

$\nabla^2 f(x^{(k)})$ é a Hessiana da função objetivo do problema quadrático (6) - define a curvatura da função.

É mais vantajoso usar a Hessiana da Lagrangeana $\nabla_{xx}^2 L(x^{(k)}, \lambda^{(k)})$ em vez de $\nabla^2 f(x^{(k)})$.

Relembrar:

$$L(x, \lambda) = f(x) - \lambda^T c(x)$$

$$\nabla_x L(x, \lambda) = \nabla f(x) - \nabla c(x) \lambda$$

$$\nabla_{xx}^2 L(x, \lambda) = \nabla^2 f(x) - \sum_{i=1}^m \lambda_i \nabla^2 c_i(x).$$

Problema quadrático preferencial - resolução

$$\begin{array}{ll} \min_{d \in \mathbb{R}^n} & d^T \nabla f(x^{(k)}) + \frac{1}{2} d^T \nabla_{xx}^2 L(x^{(k)}, \lambda^{(k)}) d \\ \text{s.a} & c(x^{(k)}) + \nabla c(x^{(k)})^T d = 0 \end{array} \quad (7)$$

A solução será designada por $d^{(k)}$.

Como se resolve o problema quadrático?

Através das condições KKT do problema (7):

- função Lagrangeana associada a (7) é

$$L_q(d, \eta) = d^T \nabla f(x^{(k)}) + \frac{1}{2} d^T \nabla_{xx}^2 L(x^{(k)}, \lambda^{(k)}) d - \eta^T \left(c(x^{(k)}) + \nabla c(x^{(k)})^T d \right)$$

η - vetor dos multiplicadores associados às restrições do **problema quadrático**

Como resolver o problema quadrático?

As condições KKT são

$$\nabla_d L_q(d, \eta) \equiv \nabla f(x^{(k)}) + \nabla_{xx}^2 L(x^{(k)}, \lambda^{(k)}) d - \nabla c(x^{(k)}) \eta = 0$$

$$\nabla_\eta L_q(d, \eta) \equiv -\left(c(x^{(k)}) + \nabla c(x^{(k)})^T d\right) = 0.$$

Este sistema é linear nas incógnitas d e η

$$\begin{cases} \nabla_{xx}^2 L(x^{(k)}, \lambda^{(k)}) d - \nabla c(x^{(k)}) \eta = -\nabla f(x^{(k)}) \\ -\nabla c(x^{(k)})^T d = c(x^{(k)}) \end{cases}$$

Solução do problema quadrático

Na forma matricial

$$\begin{pmatrix} \nabla_{xx}^2 L(x^{(k)}, \lambda^{(k)}) & -\nabla c(x^{(k)}) \\ -\nabla c(x^{(k)})^T & 0 \end{pmatrix} \begin{pmatrix} d^{(k)} \\ \eta^{(k)} \end{pmatrix} = \begin{pmatrix} -\nabla f(x^{(k)}) \\ c(x^{(k)}) \end{pmatrix}$$

Nota 1: Deve usar-se o método direto EGPP para a resolução deste sistema (se a dimensão for razoável).

Nota 2: A solução deste sistema é um vetor de $n + m$ elementos. Os primeiros n elementos formam o vetor, direção de procura, $d^{(k)}$ e os últimos m elementos formam o vetor $\eta^{(k)}$.

Técnica de globalização

Como a aproximação implementada só é válida numa pequena vizinhança de $x^{(k)}$ (aproximação à solução do problema original), só é possível garantir convergência do método se $x^{(k)}$ estiver numa vizinhança da solução, x^* - convergência local.

- Para garantir **convergência global** - convergência a partir de qualquer aproximação inicial;
- e forçar a sucessão de aproximações $\{x^{(k)}\}$ em direção à otimalidade ► diminuindo f ,
admissibilidade ► diminuindo $\|c(x)\|$,

é preciso introduzir uma **técnica de globalização** que force o algoritmo a convergir para a solução:

a procura unidimensional

em particular a **procura unidimensional aproximada** ► Critério de Armijo.

Função mérito

Nesta procura unidimensional, a função que é usada para medir o progresso do algoritmo, chama-se função mérito.

Existem várias funções mérito, que combinam termos que dependem da função objetivo e das funções das restrições:

- função **Lagrangeana aumentada**

$$M(x, \lambda) = f(x) - c(x)^T \lambda + \frac{1}{2} \beta \|c(x)\|_2^2$$

β é o parâmetro de penalidade (> 0).

Nota: Quanto mais baixo for $f(x)$, menor é $M(x, \lambda)$, e também, quanto mais próximo estivermos da região admissível ($c(x) \approx 0$), menor é $M(x, \lambda)$.

- O parâmetro β deve ser calculado por forma a que a direção de procura $d^{(k)}$ (solução do problema quadrático (7)) seja **descendente** para a função mérito M , isto é,

$$\nabla_x M \left(x^{(k)}, \lambda^{(k)} \right)^T d^{(k)} < 0$$

em que

$$\nabla_x M \left(x^{(k)}, \lambda^{(k)} \right) = \nabla f \left(x^{(k)} \right) - \nabla c \left(x^{(k)} \right) \lambda^{(k)} + \beta \nabla c \left(x^{(k)} \right) c \left(x^{(k)} \right).$$

Determinação de $\alpha^{(k)}$ (comprimento do passo)

Para calcular $\alpha^{(k)}$, tal que

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)} d^{(k)},$$

usa-se o **critério de Armijo**. O objetivo é encontrar um comprimento do passo, $\alpha^{(k)}$, que origine uma redução significativa na função mérito - dada pela condição de Armijo:

$$M\left(x^{(k+1)}, \lambda^{(k+1)}\right) \leq M\left(x^{(k)}, \lambda^{(k)}\right) + \mu \alpha^{(k)} \nabla_x M\left(x^{(k)}, \lambda^{(k)}\right)^T d^{(k)}$$

em que $0 < \mu < \frac{1}{2}$.

Critério de paragem

O processo iterativo deve parar quando as novas aproximações calculadas
► $x^{(k+1)}$ e $\lambda^{(k+1)}$ ◀ estiverem próximas de x^* e λ^* (par **KKT**);
isto é, as condições **KKT** são verificadas para umas tolerâncias ε_1 e ε_2 positivas e próximas de zero.

As condições do critério de paragem são:

medida de otimalidade

$$\|\nabla f(x^{(k+1)}) - \nabla c(x^{(k+1)}) \lambda^{(k+1)}\|_2 \leq \varepsilon_1$$

medida de admissibilidade

$$\|c(x^{(k+1)})\|_2 \leq \varepsilon_2$$

Algoritmo do método da programação quadrática sequencial

Dados $x^{(1)}, \lambda^{(1)}, \mu, \varepsilon_1$ e ε_2 ; Fazer $k = 1$

- ① Resolver o problema quadrático para calcular $d^{(k)}$ e $\eta^{(k)}$.
- ② Calcular β por forma a que a direção seja descendente para M
- ③ Calcular o comprimento do passo $\alpha^{(k)}$ (Critério de Armijo)
- ④ Fazer $x^{(k+1)} \leftarrow x^{(k)} + \alpha^{(k)} d^{(k)}$ e $\lambda^{(k+1)} \leftarrow \eta^{(k)}$
- ⑤ Se as condições do critério de paragem se verificarem então terminar com
$$\begin{cases} x^* \leftarrow x^{(k+1)} \\ \lambda^* \leftarrow \lambda^{(k+1)} \\ f^* \leftarrow f(x^{(k+1)}) \end{cases}$$
senão fazer $k \leftarrow k + 1$ e voltar para 1.

Método SQP com aproximação quasi-Newton

Solução do problema quadrático (7) é única e gera minimizante se

$$\nabla_{xx}^2 L \left(x^{(k)}, \lambda^{(k)} \right) - \text{Hessiana da quadrática}$$

for definida positiva (e se as colunas de $\nabla c(x^{(k)})$ forem linearmente independentes).

- Não há garantia de que $\nabla_{xx}^2 L \left(x^{(k)}, \lambda^{(k)} \right)$ seja definida positiva para todo o $x^{(k)}$, do processo iterativo;
- é vantajoso usar uma matriz que seja definida positiva (para garantir uma curvatura positiva da quadrática).

Sugestão: Usar uma aproximação a $\nabla_{xx}^2 L \left(x^{(k)}, \lambda^{(k)} \right)$

$$\nabla_{xx}^2 L \left(x^{(k)}, \lambda^{(k)} \right) \approx B^{(k)}$$

com $B^{(k)}$ definida positiva, $\forall k$.

Método SQP com aproximação quasi-Newton

Algumas atualizações do tipo quasi-Newton geram aproximações à Hessiana definidas positivas.

As matrizes $B^{(k)}$ são atualizadas, por exemplo, fórmula BFGS

$$B^{(k)} = B^{(k-1)} - \frac{B^{(k-1)} s^{(k-1)} s^{(k-1)T} B^{(k-1)}}{s^{(k-1)T} B^{(k-1)} s^{(k-1)}} + \frac{y^{(k-1)} y^{(k-1)T}}{y^{(k-1)T} s^{(k-1)}}$$

$k = 1, 2, \dots$, com

$$B^{(1)} = I \text{ (por exemplo)}$$

$$s^{(k-1)} = x^{(k)} - x^{(k-1)}$$

$$y^{(k-1)} = \nabla_x L(x^{(k)}, \lambda^{(k)}) - \nabla_x L(x^{(k-1)}, \lambda^{(k-1)}).$$

Método SQP com aproximação quasi-Newton

Usando $B^{(k)}$ para aproximar Hessiana da Lagrangeana $\Rightarrow$ sistema linear para calcular solução do problema quadrático $\blacktriangleright d^{(k)}$ e $\eta^{(k)} \blacktriangleleft$ é

$$\begin{pmatrix} B^{(k)} & -\nabla c(x^{(k)}) \\ -\nabla c(x^{(k)})^T & 0 \end{pmatrix} \begin{pmatrix} d^{(k)} \\ \eta^{(k)} \end{pmatrix} = \begin{pmatrix} -\nabla f(x^{(k)}) \\ c(x^{(k)}) \end{pmatrix}$$

Restrições de desigualdade

Quando (também) existem restrições de desigualdade, incorpora-se no método SQP uma estratégia de conjunto ativo.


O **conjunto ativo ótimo** é o conjunto das restrições que estão ativas na solução x^* :

- $c_i(x^*) = 0, i = 1, \dots, m$ (todas as restrições de igualdade estão ativas na solução)
- $h_j(x^*) = 0, j \in \mathcal{A} \subseteq \{1, \dots, p\}$.

Por exemplo:

$$\begin{array}{ll} \min_{x \in \mathbb{R}^2} & -x_1 x_2 \\ \text{s.a} & h_1(x) \equiv -x_1 - x_2^2 + 1 \geq 0 \\ & h_2(x) \equiv x_1 + x_2 \geq 0 \end{array}$$

Restrições de desigualdade (cont.)



Em x^*

$\Downarrow$

$$h_1(x^*) = 0$$

e

$$h_2(x^*) > 0:$$

$$p = 2$$

$$\mathcal{A} = \{1\} \in \{1, 2\}.$$

Se este conjunto fosse conhecido, aplicava-se o método SQP, considerando no problema quadrático as restrições:

$$c_i(x) = 0, i = 1, \dots, m \quad \text{e} \quad h_j(x) = 0, j \in \mathcal{A}.$$

Restrições de desigualdade (cont.)

- 1 começa-se por calcular uma aproximação inicial $x^{(1)}$ que seja admissível;
- 2 define-se um problema quadrático com base nas restrições $c(x) = 0$ e num subconjunto das restrições $h(x) \geq 0$ impostas como igualdades
 - Nota 1: define o *conjunto de trabalho*
 - Nota 2: os gradientes das restrições deste conjunto devem ser linearmente independentes;
- 3 com a direção de procura obtida da resolução do problema quadrático, calcula-se uma nova aproximação,
- 4 atualiza-se o *conjunto de trabalho*, adicionando e/ou retirando restrições
- 5 repete-se o processo, até convergir ...