

Métodos de Otimização em Contexto Industrial

Otimização não linear multidimensional sem restrições
Métodos do gradiente

Ana Maria A. C. Rocha

Departamento de Produção e Sistemas

Universidade do Minho

arocha@dps.uminho.pt

Ano letivo 2023/24

Problema sem restrições

$$\min_{x \in \mathbb{R}^n} f(x) \quad (n > 1)$$

- Métodos de procura direta (que **não** usam derivadas)
- Métodos do gradiente.

Métodos do gradiente

- usam informação da função e das derivadas (gradiente e/ou Hessiana);
- só podem ser usados na resolução de **problemas diferenciáveis**;
- convergem mais rapidamente do que os métodos de procura direta.

Métodos do gradiente

- geram uma sucessão de aproximações $\{x^{(k)}\}$ à solução:

$$x^{(k+1)} = x^{(k)} + \alpha^k d^{(k)}$$

em que $d^{(k)}$ (vetor) é a **direção de procura** (ou passo) e α^k (escalar) é o **comprimento do passo**.

- A equação iterativa para o cálculo da direção de procura é diferente para cada método.

Métodos do gradiente

Algoritmo geral dos métodos do gradiente

Dados: aproximação inicial $x^{(1)}$, $\varepsilon > 0$ (≈ 0), $k \leftarrow 1$

Enquanto $\underbrace{\left\| \nabla f(x^{(k)}) \right\|_2}_{\text{medida de estacionaridade}} > \varepsilon$ **fazer**

- calcular $d^{(k)}$ (direção de procura ou passo)
- calcular $\alpha^{(k)}$ (comprimento do passo)
- definir $x^{(k+1)} \leftarrow x^{(k)} + \alpha^{(k)} d^{(k)}$
- $k = k + 1$

Fim de enquanto

Solução: $\begin{cases} x^* \approx x^{(k+1)} \\ f^* \approx f(x^{(k+1)}) \end{cases}$

Métodos do gradiente mais usados

Em cada iteração k , para calcular a direção de procura ou passo $d^{(k)}$:

- método de Segurança de Newton

direção é $d_{SN}^{(k)}$

- método quasi-Newton

direção é $d_{QN}^{(k)}$

para calcular o comprimento do passo $\alpha^{(k)}$ – se a direção for **descendente** para $f(x)$ em $x^{(k)}$:

- critério de Armijo.

Método de Newton básico

O método de Newton é baseado numa aproximação local de $f(x)$ por uma função quadrática.

Seja $x^{(k)}$ uma aproximação a x^* .

Usando a expansão em série de Taylor de f , no ponto $x = x^{(k)} + d$:

$$f(x^{(k)} + d) = f(x^{(k)}) + \nabla f(x^{(k)})^T d + \frac{1}{2} d^T \nabla^2 f(x^{(k)}) d + \dots$$

e apenas os três primeiros termos da série, obtém-se uma função quadrática em d

$$\begin{aligned} f(x^{(k)} + d) &\approx f(x^{(k)}) + \nabla f(x^{(k)})^T d + \frac{1}{2} d^T \nabla^2 f(x^{(k)}) d \\ &\approx q(d) \end{aligned}$$

O mínimo de $q(d)$ vai originar uma nova aproximação ao mínimo de $f(x)$.

... a direção Newton

Derivando em ordem a d e igualando a zero ($\nabla q(d) = 0$), obtém-se

$$\nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) d = 0$$
$$\Leftrightarrow$$

$$\nabla^2 f(x^{(k)}) d_N^{(k)} = -\nabla f(x^{(k)}) \quad (1)$$

A solução do **sistema (linear) Newton** (1) é o vetor $d_N^{(k)}$ – **direção Newton**.

- Usa-se EGPP para resolver o sistema Newton.
- A nova aproximação


$$x^{(k+1)} \leftarrow x^{(k)} + d_N^{(k)}$$

não é necessariamente o minimizante de $f(x)$ e o processo deve ser repetido a partir de $x^{(k+1)}$.

1. direção Newton ascendente (!)

- No entanto, a direção $d_N^{(k)}$ (solução do sistema Newton) pode ser **ascendente** para f em $x^{(k)}$, ou seja,


$$\nabla f(x^{(k)})^T d_N^{(k)} > 0$$



2. direção Newton ortogonal ao gradiente (!)

- Ou, a direção $d_N^{(k)}$ (solução do sistema Newton) pode ser **ortogonal** ao gradiente calculado em $x^{(k)}$, ou seja,

$$\nabla f(x^{(k)})^T d_N^{(k)} = 0$$




3. direção Newton descendente, mas ...

- ou, a direção $d_N^{(k)}$ pode ser **descendente** para f em $x^{(k)}$, i.e.

$$\nabla f(x^{(k)})^T d_N^{(k)} < 0$$

mas ser muito grande e $f(x^{(k)} + d_N^{(k)}) \geq f(x^{(k)})$ (!)



4. sistema Newton não tem solução única (!)

- ou ainda, a matriz $\nabla^2 f(x^{(k)})$ pode ser singular, o que significa que o sistema Newton não tem solução ou tem uma infinidade de soluções



$\nexists d_N^{(k)}$ (não existe direção ou não é única)

Limitações do Método de Newton

Para ultrapassar as limitações descritas com a direção Newton, em cada iteração k , **implementam-se** as seguintes soluções que a seguir se apresentam – dando origem ao



método de Segurança de Newton

Método de Segurança de Newton

Em qualquer iteração k :

- Quando $\nabla^2 f(x^{(k)})$ é singular

$$\Rightarrow \text{usar } d_{SN}^{(k)} = -\nabla f(x^{(k)})$$

($-\nabla f(x^{(k)})$ é a direção de descida máxima e é descendente para f)

- Quando $d_N^{(k)}$ é ortogonal ao gradiente $\Leftrightarrow \nabla f(x^{(k)})^T d_N^{(k)} \approx 0$

$$\Rightarrow \text{usar } d_{SN}^{(k)} = -\nabla f(x^{(k)})$$

- Quando $d_N^{(k)}$ é ascendente $\Leftrightarrow \nabla f(x^{(k)})^T d_N^{(k)} > \eta$

$$\Rightarrow \text{usar } d_{SN}^{(k)} = -d_N^{(k)}$$

- Quando $d_N^{(k)}$ é descendente

$$\Rightarrow \text{usar } d_{SN}^{(k)} = d_N^{(k)}$$

NOTA: $d_{SN}^{(k)}$ é descendente, para todo o k .

Propriedades do método de Newton

O método de Newton tem convergência

- **local**
(a convergência para a solução só é garantida se a aproximação inicial $x^{(1)}$ estiver na vizinhança da solução);
- **quadrática**
(verifica-se

$$\|x^{(k+1)} - x^*\| \leq \gamma \|x^{(k)} - x^*\|^2, \gamma > 0);$$

O método de Newton possui a propriedade da "**terminação quadrática**", i.e., se $f(x)$ ($x \in \mathbb{R}^n$) for uma função quadrática e convexa o método de Newton necessita no máximo de n iterações para encontrar a solução.

Desvantagens do método de Newton

- Cálculo das segundas derivadas:
 - se a expressão de f é complicada, estas tornam-se difíceis de calcular;
 - exigem um grande esforço de cálculo quando n é grande.
- A convergência é local.

Para ultrapassar a convergência local

deve implementar-se uma técnica de globalização para garantir que o método converge para a solução, a partir de qualquer aproximação inicial.

A técnica de globalização implementa-se


- para garantir que o método converge, qualquer que seja a aproximação inicial $x^{(1)}$ (i.e., $x^{(1)}$ pode estar fora da região de convergência do método);
- para garantir que o método converge para um **ponto estacionário** que é minimizante.

- 1 Procura unidimensional (line search) $\left\{ \begin{array}{l} \text{exata} \\ \text{aproximada} \end{array} \right.$
- 2 Região de confiança (trust region)

Procura unidimensional aproximada

Dados $x^{(k)}$ e $d^{(k)}$, calcular $\alpha^{(k)}$ – **comprimento do passo** – que origina uma redução significativa no valor de f na nova aproximação $x^{(k)} + \alpha^{(k)}d^{(k)}$

$$f(x^{(k)} + \alpha^{(k)}d^{(k)}) \leq f(x^{(k)}) + \mu\alpha^{(k)}\nabla f(x^{(k)})^T d^{(k)}$$



Procedimento para calcular $\alpha^{(k)}$ que origina uma redu  o significativa na fun  o objetivo, isto  , verifica

- a condi  o de Armijo

$$f(x^{(k)} + \alpha^{(k)} d^{(k)}) \leq f(x^{(k)}) + \mu \alpha^{(k)} \nabla f(x^{(k)})^T d^{(k)}$$

com $0 < \mu < \frac{1}{2}$.

- Se $d^{(k)}$ for descendente para f , ou seja,

$$\nabla f(x^{(k)})^T d^{(k)} < 0$$

existe um valor de

$$\alpha^{(k)} \in (0, 1]$$

que verifica esta condi  o.

Algoritmo do crit rio de Armijo para calcular $\alpha^{(k)}$

Dados $x^{(k)}$, $d^{(k)}$, $\nabla f(x^{(k)})$, $f(x^{(k)})$ e μ

- 1 $\alpha \leftarrow 1$
- 2 $\bar{x} \leftarrow x^{(k)} + \alpha d^{(k)}$
- 3 se $\left(f(\bar{x}) \leq f(x^{(k)}) + \mu \alpha \nabla f(x^{(k)})^T d^{(k)} \right)$ ent o
fazer $\alpha^{(k)} = \alpha$
sen o
 $\alpha \leftarrow \alpha/2$ e voltar a 2.

Critério de paragem

Condições de paragem

- estimativa do erro relativo da aproximação

$$\frac{\|x^{(k+1)} - x^{(k)}\|_2}{\|x^{(k+1)}\|_2} \leq \varepsilon_1$$

- estimativa do erro relativo da função objetivo

$$\frac{|f(x^{(k+1)}) - f(x^{(k)})|}{|f(x^{(k+1)})|} \leq \varepsilon_2$$

- medida de estacionaridade

$$\|\nabla f(x^{(k+1)})\|_2 \leq \varepsilon_3$$

ε_1 , ε_2 e ε_3 são quantidades positivas e próximas de zero.

Nota: Diferentes implementações do método podem ter condições diferentes no critério de paragem.

Métodos do gradiente

Algoritmo geral dos métodos do gradiente

Dados: aproximação inicial $x^{(1)}$, $k \leftarrow 1$

Enquanto critério de paragem não for verdadeiro **fazer**

- calcular $d^{(k)}$ (direção de procura ou passo)
- calcular $\alpha^{(k)}$ (comprimento do passo)
- definir $x^{(k+1)} \leftarrow x^{(k)} + \alpha^{(k)} d^{(k)}$
- $k = k + 1$

Fim de enquanto

Solução:
$$\begin{cases} x^* \approx x^{(k+1)} \\ f^* \approx f(x^{(k+1)}) \end{cases}$$

Método de Segurança de Newton

Algoritmo para o cálculo da direção de Segurança de Newton

Dados $x^{(k)}$ e η ,

Resolver o sistema linear Newton $\nabla^2 f(x^{(k)}) d_N^{(k)} = -\nabla f(x^{(k)})$ por EGPP

se (o sistema linear tem solução única - $\exists d_N^{(k)}$) então

se $|\nabla f(x^{(k)})^T d_N^{(k)}| \leq \eta \|\nabla f(x^{(k)})\|_2 \cdot \|d_N^{(k)}\|_2$ com $\eta > 0 (\approx 0)$

então $d_{SN}^{(k)} \leftarrow -\nabla f(x^{(k)})$

senão

se $\nabla f(x^{(k)})^T d_N^{(k)} > \eta \|\nabla f(x^{(k)})\|_2 \cdot \|d_N^{(k)}\|_2$ com $\eta > 0 (\approx 0)$

então $d_{SN}^{(k)} \leftarrow -d_N^{(k)}$

senão $d_{SN}^{(k)} \leftarrow d_N^{(k)}$

senão

$d_{SN}^{(k)} \leftarrow -\nabla f(x^{(k)})$

Como evitar o cálculo das 2^{as} derivadas no método de Newton

método de Newton

$$\nabla^2 f(x^{(k)}) d_N^{(k)} = -\nabla f(x^{(k)})$$

Para evitar o cálculo das 2^{as} derivadas para a Hessiana, $\nabla^2 f(x)$, pode usar-se uma aproximação:

$$B^{(k)} \approx \nabla^2 f(x^{(k)})$$

e a direção de procura seria calculada pela resolução deste sistema linear (por EGPP)

$$B^{(k)} d_{QN}^{(k)} = -\nabla f(x^{(k)})$$

A direção quasi-Newton

- Como o sistema Newton pode ser escrito na forma equivalente - embora não aconselhável na prática,

$$d_N^{(k)} = - \left(\nabla^2 f(x^{(k)}) \right)^{-1} \nabla f(x^{(k)})$$

pode usar-se, em cada iteração k , uma aproximação à **inversa da Hessiana**

$$H^{(k)} \approx \left(\nabla^2 f(x^{(k)}) \right)^{-1}$$

e calcular a direção pelo produto da matriz pelo vetor

$$d_{QN}^{(k)} = -H^{(k)} \nabla f(x^{(k)})$$

$d_{QN}^{(k)}$ - é a **direção quasi-Newton**.

Método quasi-Newton

Evita-se desta forma:

- o cálculo das segundas derivadas;
- a resolução de um sistema linear em cada iteração, substituindo-o pelo produto de uma matriz por um vetor.

As equações que descrevem o método quasi-Newton são:

$$\begin{cases} d_{QN}^{(k)} = -H^{(k)}\nabla f(x^{(k)}), \\ x^{(k+1)} = x^{(k)} + \alpha^{(k)}d_{QN}^{(k)} \quad \text{para } k = 1, 2, \dots \end{cases}$$

Propriedades da matriz H

- A matriz H deve aproximar, o melhor possível, a inversa de $\nabla^2 f(x^{(k)})$, ou seja, deve verificar a **condição secante**:

$$H^{(k)} y^{(k-1)} = s^{(k-1)}$$

com

$$y^{(k-1)} = \nabla f(x^{(k)}) - \nabla f(x^{(k-1)})$$

(variação verificada no gradiente da iteração $k - 1$ para a iteração k)

$$s^{(k-1)} = x^{(k)} - x^{(k-1)} = \alpha^{(k-1)} d_{QN}^{(k-1)}$$

(variação verificada em x)

Propriedades da matriz H

- A matriz H deve preferencialmente ser

$$\begin{cases} \textbf{simétrica} & (\text{pois } \nabla^2 f(x^{(k)})^{-1} \text{ também é simétrica}) \\ \textbf{definida positiva} & (\text{pois a direção } d_{QN}^{(k)} = -H^{(k)}\nabla f(x^{(k)}) \end{cases}$$

é **descendente** para f em $x^{(k)}$).

Para que estas propriedades se conservem ao longo do processo iterativo, a **matriz inicial** $H^{(1)}$, para $k = 1$, deve ser também **simétrica** e **definida positiva**. Pode usar-se, por exemplo

$$H^{(1)} = I.$$

Fórmulas de atualização que conservam a matriz H simétrica e definida positiva

Davidon, Fletcher e Powell - **DFP**

$$H^{(k)} = H^{(k-1)} - \frac{H^{(k-1)} y^{(k-1)} y^{(k-1)^T} H^{(k-1)}}{y^{(k-1)^T} H^{(k-1)} y^{(k-1)}} + \frac{s^{(k-1)} s^{(k-1)^T}}{s^{(k-1)^T} y^{(k-1)}}$$

Broyden, Fletcher, Goldfarb e Shanno - **BFGS**

$$H^{(k)} = \left(I - \frac{s^{(k-1)} y^{(k-1)^T}}{s^{(k-1)^T} y^{(k-1)}} \right) H^{(k-1)} \left(I - \frac{y^{(k-1)} s^{(k-1)^T}}{s^{(k-1)^T} y^{(k-1)}} \right) + \frac{s^{(k-1)} s^{(k-1)^T}}{s^{(k-1)^T} y^{(k-1)}}$$

Propriedades do método quasi-Newton

O método quasi-Newton tem convergência

- **local**

(a convergência para a solução só é garantida se a aproximação inicial $x^{(1)}$ estiver na vizinhança da solução);

- **superlinear**

(verifica-se

$$\|x^{(k+1)} - x^*\| \leq \gamma_k \|x^{(k)} - x^*\|$$

com a sucessão $\{\gamma_k\} \rightarrow 0$ quando $k \rightarrow \infty$);

O método quasi-Newton satisfaz a propriedade da "**terminação quadrática**" (ou seja, o mínimo de uma função quadrática $q(x)$, $x \in \mathbb{R}^n$, obtém-se em n , ou menos, do que n iterações).

Limitação do método quasi-Newton

★ Os erros de arredondamento que se cometem nos cálculos podem fazer com que $H^{(k)}$ deixe de ser definida positiva e a direção $d_{QN}^{(k)}$ deixa de ser descendente para f em $x^{(k)}$



Solução: fazer $H^{(k)} = I$ (neste caso $H^{(k)}$ é simétrica e definida positiva)



$$d_{QN}^{(k)} = -\nabla f(x^{(k)})$$

Métodos do gradiente

Algoritmo geral dos métodos do gradiente

Dados: aproximação inicial $x^{(1)}$, $k \leftarrow 1$

Enquanto critério de paragem não for verdadeiro **fazer**

- calcular $d^{(k)}$ (direção de procura ou passo)
- calcular $\alpha^{(k)}$ (comprimento do passo)
- definir $x^{(k+1)} \leftarrow x^{(k)} + \alpha^{(k)} d^{(k)}$
- $k = k + 1$

Fim de enquanto

Solução:
$$\begin{cases} x^* \approx x^{(k+1)} \\ f^* \approx f(x^{(k+1)}) \end{cases}$$

Algoritmo para o cálculo da direção quasi-Newton

Algoritmo para o cálculo da direção quasi-Newton

Dado $x^{(k)}$

Calcular $d_{QN}^{(k)} \leftarrow -H^{(k)} \nabla f(x^{(k)})$, sendo $H^{(k)}$ dada por:

se $k = 1$ então

$$H^{(k)} \leftarrow I$$

senão

$$\begin{cases} s^{(k-1)} \leftarrow x^{(k)} - x^{(k-1)} \\ y^{(k-1)} \leftarrow \nabla f(x^{(k)}) - \nabla f(x^{(k-1)}) \\ \text{atualizar } H^{(k)} \text{ pela fórmula } \mathbf{DFP} \text{ ou } \mathbf{BFGS} \end{cases}$$

se $d_{QN}^{(k)}$ não é descendente $(\nabla f(x^{(k)}))^T d_{QN}^{(k)} \geq 0$ então

$$\text{fazer } d_{QN}^{(k)} \leftarrow -\nabla f(x^{(k)})$$