




# Agenda

---



## CRISP-DM: Compreensão dos Dados

- Análise Exploratória dos Dados (EDA)
- Exemplo



## Acompanhamento ao projeto




# Cross Industry Process for Data Mining (CRISP-DM)



# CRISP-DM – Compreensão dos Dados



# CRISP-DM – Atividades da Compreensão de Dados





# CRISP-DM – Compreensão de Dados

Familiarização com os dados e percepção da sua utilidade.

Processo de coleta de dados (ex.: via *query* a DW, *download* .csv, etc.).

Descrição dos dados (ex.: atributos e significado, tipos de dados, nº de linhas, etc.).

Identificação de problemas na qualidade dos dados e possíveis soluções a implementar ao longo do projeto.



# Tipos de Atributos

Data Mining é frequentemente aplicado a simples conjuntos de dados em formato **tabular**.


As tabelas contêm um conjunto de **instâncias** (exemplos, linhas) e **atributos** (colunas).

Em dados tabulares, os atributos são maioritariamente:

- **Catégoricos:** valores qualitativos; discretos ou enumerados; “classes”. Podem ser:
  - **Nominais:** sem ordem nos valores possíveis (ex.: “cão”, “gato”, “pássaro”);
  - **Ordenados:** valores possíveis seguem uma determinada ordem (ex.: “Janeiro”, “Fevereiro”, “Março”, ... ).
- **Numéricos:** valores quantitativos; inteiros ou reais, com ou sem limites. Podem ser:
  - **Discretos:** opções finitas (ex.: dias do mês, tamanho do calçado, ... );
  - **Contínuos:** opções infinitas (ex.: altura, peso, ... ).

O tipo de atributo vai estabelecer o modo como este é analisado e manipulado.

# Tipos de Atributos





# Tipos de Atributos

|                                 |               | Categóricos          |                                      | Numéricos               |                  |
|---------------------------------|---------------|----------------------|--------------------------------------|-------------------------|------------------|
|                                 |               | Nominais             | Ordenados                            | Intervalos              | Ratio            |
| Operações Lógicas / Matemáticas | $\div \times$ | X                    | X                                    | X                       | ✓                |
|                                 | $+ -$         | X                    | X                                    | ✓                       | ✓                |
|                                 | $> <$         | X                    | ✓                                    | ✓                       | ✓                |
|                                 | $= \neq$      | ✓                    | ✓                                    | ✓                       | ✓                |
| Exemplos (valores)              |               | Género (M, F, Outro) | Opinião (concordo, neutro, discordo) | Latitude (de +90 a -90) | Idade (0 a 100)  |
| Medida de tendência central     |               | Moda                 | Mediana                              | Média aritmética        | Média geométrica |





# Análise Exploratória de Dados (EDA)

“EDA está maioritariamente relacionada com a visualização e sumarização dos dados antes de se iniciar o processo de modelação.

Razões para a criação de gráficos na exploração de dados:

- **Compreender** as propriedades dos dados;
- **Inspecionar** atributos qualitativos ao invés de olhar para grandes tabelas de dados em bruto;
- **Descobrir** novos padrões ou associações;
- Entre outras...

Análise interativa é a melhor forma de explorar os dados.” (Jeff Leck, 2015)

Análises de dados podem ser:

- **Univariadas:** apenas um atributo;
- **Multivariadas:** 2 ou mais atributos (mais comum).



# Análise Exploratória de Dados (EDA)

EDA pode ser feito em diversas ferramentas.

**Python:** pandas-profiling, sweetviz, AutoViz, dtale, ...

**R:** datavis, plotly, ggplot, ...

**Weka.**

**Tableau.**


**Excel.**

...








# EDA: Titanic Dataset

## Interactions



EDA com pandas-profiling



EDA com AutoViz




# Agenda

---



## CRISP-DM: Preparação dos Dados

- Valores Omissos
- *Outliers*
- Transformações (numéricas e categóricas)
- Seleção de Atributos
- Dados Desbalanceados



## Acompanhamento ao projeto



# Cross Industry Process for Data Mining (CRISP-DM)




# CRISP-DM – Preparação dos Dados





# CRISP-DM – Atividades da Preparação dos Dados





# CRISP-DM – Preparação dos Dados

Também conhecido como pré-processamento dos dados.

**Fundamental** para que haja sucesso em *Data Mining*!

Inclui diversas etapas, nomeadamente:

- Verificação da qualidade e integridade dos dados.
- Tratamento de valores omissos/desconhecidos (nulos).
- Detecção e tratamento de *outliers*.
- Transformações de atributos (numéricos e categóricos).
- Seleção de atributos (*a.k.a.: feature selection*).





# Valores omissos/desconhecidos – soluções

**Ignorar/remover** os registos com valores omissos (linhas ou colunas).

**Transformar** todos os valores omissos numa “classe” (apenas os categóricos): “**desconhecido**”.

**Substituir** (*imputation*) cada valor omissos por:

- Valor dado por um especialista do negócio (*case substitution*);
- Valor médio, mediana ou mais comum (moda) do respetivo atributo;
- Valor retirado de outra base de dados (*cold deck*);
- Valor do exemplo mais semelhante/próximo (*hot deck*);
- Valor estimado por um modelo (ex.: regressão linear);
- Combinação dos métodos anteriores (*multiple combination*).

Ferramentas para imputação de valores omissos:

- Python: <https://scikit-learn.org/stable/modules/impute.html>;
- R: <https://www.analyticsvidhya.com/blog/2016/03/tutorial-powerful-packages-imputing-missing-values/>;
- Rapidminer: [https://docs.rapidminer.com/latest/studio/operators/cleansing/missing/impute\\_missing\\_values.html](https://docs.rapidminer.com/latest/studio/operators/cleansing/missing/impute_missing_values.html).



# Outliers

**Outliers:** Valores atípicos provenientes de erros na coleta dos dados ou de eventos raros.

Se não estiverem relacionados com o fenómeno em estudo, **aumentam a complexidade** dos dados e **dificultam a aprendizagem** (na fase de modelação).

Solução: detetar e eliminar estes valores.

Deteção:

- **Uso de especialistas no negócio;**
- **Visualização de dados e estatísticas:** diagrama de caixa e 1.5 x desvio padrão, etc.;
- **Uso de métodos de deteção de *outliers*:** *clustering*, *Local Outlier Factor (LOF)*, *Isolation Forest*, etc.

Eliminação: **ignorar/remover** registos ou **substituir** (*imputation*).

Ferramentas: Python ([https://scikit-learn.org/stable/modules/outlier\\_detection.html](https://scikit-learn.org/stable/modules/outlier_detection.html)), R (<https://statsandr.com/blog/outliers-detection-in-r/>), Rapidminer ([https://docs.rapidminer.com/latest/studio/operators/cleansing/outliers/detect\\_outlier\\_distances.html](https://docs.rapidminer.com/latest/studio/operators/cleansing/outliers/detect_outlier_distances.html)), etc.



# Transformações de atributos: numérico → numérico

Por vezes é útil **normalizar** ou **reescalar** atributos numéricos devido a discrepâncias de valores (dentro de um determinado atributo ou entre atributos).

O objetivo é converter os valores para uma nova escala (*normalization/scaling*), de modo a garantir a mesma importância para diferentes atributos.

Exemplos de transformações matemáticas (atributos numéricos):

- ***Min-max;***
- ***Z-score;***
- ***Max absolute;***
- ***Robust scaling.***

Ferramentas:

- Python: <https://towardsdatascience.com/data-normalization-with-pandas-and-scikit-learn-7c1cc6ed6475>;
- R: <https://medium.com/swlh/data-normalisation-with-r-6ef1d1947970>;
- Rapidminer: <https://docs.rapidminer.com/latest/studio/operators/cleansing/normalization/normalize.html>.



# Transformações de atributos: numérico $\rightarrow$ categórico

Transformação dos valores numéricos em categorias, por exemplo via definição de intervalos.

Exemplo: temperatura, com definições de classes como “frio”, “morno” e “quente”.

Duas formas de o fazer:

- Definir número de classes N com **intervalos espaçados de igual comprimento numérico**;  
Exemplo:  $0 \leq x \leq 1$ ,  $N=3$ ; Classes: A  $\rightarrow [0, 0.33[$ ; B  $\rightarrow [0.33, 0.66[$ ; C  $\rightarrow [0.66, 1]$ .
- Definir número de classes N, de forma a que **cada classe tenha o mesmo número de exemplos**.

Ferramentas:

- Python: <https://towardsdatascience.com/data-preprocessing-with-python-pandas-part-5-binning-c5bd5fd1b950>;
- R: <https://r-coder.com/cut-r/>;
- Rapidminer: [https://docs.rapidminer.com/latest/studio/operators/cleansing/binning/discretize\\_by\\_bins.html](https://docs.rapidminer.com/latest/studio/operators/cleansing/binning/discretize_by_bins.html).



# Transformações de atributos: categórico → categórico

Usado quando existe um número muito elevado de classes.

Permite simplificar os modelos e facilitar a aprendizagem.

Pode ser feito pela agregação de classes numa única.

- Exemplo: Marcas de automóveis -> respetiva gama.
  - “BMW”, “Mercedes”, ... -> “gama alta”;
  - ...
  - “Smart”, “Citroen”, ... -> “gama baixa”.

Pode usar-se a frequência em que a classe aparece nos dados, agregando classes menos frequentes em “Outros”.

- PCP (*Percentage Categorical Pruned*).
- Implementações:
  - Python (<https://pypi.org/project/cane/>);
  - R (<https://cran.r-project.org/web/packages/rminer/index.html>).



# Transformações de atributos: categórico → numérico

Alguns algoritmos de *Machine Learning* **não são capazes de lidar com valores categóricos**.

Nestes casos, é necessário converter o texto de acordo com um sistema de mapeamento.

Exemplo: cores (“vermelho”, “azul”, “amarelo”). Possibilidades:

- **Ordinal Encoder**: “vermelho” -> 1; “azul” -> 2; “amarelo” -> 3.
- **One-hot Encoding (1-of-C)**: “vermelho” -> (1,0,0); “azul” -> (0,1,0); “amarelo” -> (0,0,1).
- **Inverse Document Frequency (IDF)**: baseado na frequência da classe no dataset, onde valores mais próximos do zero são mais frequentes.
- ...

Ferramentas:

- Python (<https://pbpython.com/categorical-encoding.html>, <https://pypi.org/project/cane/>);
- R (<https://stats.idre.ucla.edu/r/library/r-library-contrast-coding-systems-for-categorical-variables/>, <https://cran.r-project.org/web/packages/rminer/index.html>);
- Weka (<https://machinelearningmastery.com/transform-machine-learning-data-weka/>).

# Transformações de atributos: categórico → numérico

Apesar da transformação categórica mais comum ser o *one-hot encoding*, casos com elevado número de classes podem ser problemáticos.

Exemplo:

- +100 países -> centenas de colunas!
- +10.000 cidades -> milhares de colunas!!!

Possíveis soluções:

- IDF: valor numérico com base na frequência no *dataset*;
- PCP: agrupar valores pouco frequentes no *dataset* em classe “outros”;
- Outras alternativas: latitude e longitude.





# Seleção de Atributos

Nem todos os atributos influenciam da mesma forma o conceito a aprender (variável a prever).

**Atributos irrelevantes** podem aumentar o **ruído** nos dados, resultando em:

- Dificuldades na aprendizagem;
- Modelos mais complexos -> mais difíceis de explicar;
- Maior exigência computacional (ex.: mais memória, tempo de execução, ...).

## Como resolver?

- **Uso de especialistas do negócio:** conhecimento *a priori*;
- **Uso de filtros:** análise de correlações (ex.: gráfico de correlação de *Spearman*, coeficiente de correlação);
- **Métodos *wrapper*:** aplicados a modelos de aprendizagem.

**Ferramentas:** Python (<https://machinelearningmastery.com/feature-selection-machine-learning-python/>), R (<https://www.machinelearningplus.com/machine-learning/feature-selection/>), Weka (<https://machinelearningmastery.com/perform-feature-selection-machine-learning-data-weka/>), Rapidminer ([https://docs.rapidminer.com/latest/studio/operators/modeling/optimization/feature\\_selection/optimize\\_selection.html](https://docs.rapidminer.com/latest/studio/operators/modeling/optimization/feature_selection/optimize_selection.html)).





# Seleção de Exemplos

Não só os atributos têm influência na aprendizagem, também os exemplos devem ser representativos do fenómeno a estudar: **quantos mais registos, melhor!**

Em muitos casos do mundo real, a variável a prever é **desbalanceada**, i.e., existem muitos registos mas relativos a apenas um dos fenómenos

- Exemplo: 😊 previsão da aprovação a esta UC -> “aprovado”: 98%; “reprovado”: 2%.

Desbalanceamento nos dados **pode prejudicar a aprendizagem!** Como equilibrar/balancear os dados (apenas em **dados de treino!!!**) :

- **Undersampling**, reduzir os registos da classe maioritária “aprovado” (ex.: *random*, *Tomek Links*);
- **Oversampling**, aumentar os registos da classe minoritária “reprovado” (ex.: amostragem aleatória, geração de dados sintéticos -> *SMOTE*, *Gaussian Copula*).

Ferramentas:

- Python (<https://imbalanced-learn.org/stable/references/index.html>, <https://sdv.dev/SDV/index.html>);
- R (<https://www.analyticsvidhya.com/blog/2016/03/practical-guide-deal-imbalanced-classification-problems/>).

Exemplo: <https://repositorium.sdum.uminho.pt/bitstream/1822/73976/1/paper88.pdf>