

Metodologias para Ciência de Dados


Mestrado em Engenharia e Ciência de Dados

2025/26



Manuel Filipe Santos




Paradigmas de Aprendizagem Automática



Descoberta de Conhecimento em Bases de Dados



[Recursos]



[Metodologia CRISP-DM]

Aprendizagem Automática


$$Y=f(X)$$

[Aprendizagem supervisionada por indução]

Dados: n observações (exemplos) $\{(x_1, y_1), \dots, (x_n, y_n)\}$

X : espaço de entradas $x_i \in X$
 Y : espaço de saídas $y_i \in Y$
 H : espaço de hipóteses $h_i \in H$

		Atributos			Classe
Dados	x1	x11	x12 ...	x1m	y1
	x2	x11	x12 ...	x1m	y2
	...	...			...
	xn	x11	x12 ...	x1m	yn



Recorrendo a algoritmos de AA encontrar a função h (hipótese) que mais se aproxima de f (*modelo, padrão, conhecimento*)

f tem a capacidade de ‘prever’ o valor de Y para novos valores de X

$$\underset{\text{conj-treino}}{\text{erro}}(h) > \underset{\text{conj-todo}}{\text{erro}}(h')$$

[Sobreajustamento (*overfitting*)]

Dada o espaço de hipóteses H , $h \in H$ estará sobreajustado em relação ao conjunto de treino se existir uma hipótese $h' \in H$ em que:

1. h apresenta um erro inferior quando aplicada ao conjunto de dados de treino;
2. h' apresenta um erro inferior quando aplicada ao conjunto de dados global.

$$\text{erro}(f) = e(\text{bias}, \text{var}, \text{noise})$$

[erro da previsão]

bias – viés – pressupostos de simplificação de f por forma seja mais fácil a aprendizagem / para estimar valores de Y cujos valores de X não pertencem ao conjunto de entrada

Exemplos de técnicas de AA com viés baixos: AD, SVM

var – variância – impacto que a utilização de um conjunto de dados de treino diferente tem nos valores de Y estimados por f

Exemplos de técnicas de AA com variância alta: AD, SVM

noise – erro irreduzível (ruído) – inerente ao problema – não pode ser reduzido. Desconhecimento sobre que fatores influenciam o mapeamento das variáveis de entrada com a variável de saída.

Aprendizagem Automática


$$bias \approx \frac{k}{var}$$

[bias vs. var trade-off]


- Diminuir a variância aumenta o viés
- Diminuir o viés aumenta a variância
- É possível configurar o compromisso viés-var ajustando alguns dos parâmetros dos algoritmos de AA

Tipo de algoritmo de AA	Viés	Variância
Paramétrico ou linear	+	-
Não-paramétrico ou não-linear	-	+

Avaliação – Framework (qual a melhor hipótese h)



Avaliação – Medidas de Desempenho





Avaliação – Métricas para Classificação

		Valor previsto		
		Positivos Previstos	Negativos Previstos	
Valor esperado	Positivos	VP Erro Tipo II	FN Erro Tipo I	True Positive Rate (TPR), Sensibilidade, Recall $\frac{VP}{VP + FN}$
	Negativos	FP Erro Tipo I	VN	True Negative Rate (TNR), Especificidade $\frac{VN}{FP + VN}$
Acuidade $\frac{VP + VN}{População}$		Positive Predictive Value (PPV), Precisão $\frac{VP}{VP + FP}$	F-measure Média harmónica Precisão e recall $\frac{2VP}{2VP + FP + FN}$	Matthews Correlation Coefficient (MCC) Representa a Matriz de Confusão Comparação de Matrizes de confusão $\frac{VP \times VN - FP \times FN}{\sqrt{(VP + FP)(VP + FN)(VN + FP)(VN + FN)}}$

[Métricas baseadas na Matriz de Confusão]


Avaliação – Métricas para Classificação

Curva ROC – Receiving Operating Curve – representa a relação entre sensibilidade e especificidade fazendo variar de forma contínua o cutoff point (entre duas classes)




Curva 1

A B C




Curva 2




Curva 3

Avaliação – Métodos de Amostragem




Avaliação – Métodos de Amostragem

HOLDOUT




Cross-Validation



Os modelos são treinados e testados k vezes. O erro final de generalização é dado pela média dos erros de validação obtidos durante k vezes. Os valores de k podem variar entre 2 e n , embora o valor 10 seja o mais popular (10-Fold Cross-Validation).


Aprendizagem Automática – Árvores de decisão



if Sexo = Female and Classe = First then Yes (97 / 4)
 if Sexo = Female and Classe = Second and Idade > 56 then No (0 / 2)
 if Sexo = Female and Classe = Second and Idade ≤ 56 then Yes (59 / 8)
 if Sexo = Female and Classe = Third and Tarifa > 24.808 then No (1 / 18)
 if Sexo = Female and Classe = Third and Tarifa ≤ 24.808 then Yes (82 / 51)
 if Sexo = Male then No (110 / 484)

$$Gini(A) = \sum p(v) \sum_{i \neq j} p(i|v) p(j|v)$$

[Atributo mais informativo (discriminatório)]




seja T a árvore de decisão a induzir
seja S o conjunto de exemplos para aprendizagem
se todos os exemplos de S pertencem à mesma classe C
então a árvore tem um nó C
Senão selecionar o atributo A mais informativo cujos valores são v1,..., vn
 Particionar S em n subconjuntos S1,..., Sn para cada valor vi de A
 Construir (recursivamente) subárvores T1,..., Tn para cada S1,..., Sn

[Algoritmo ID3]

	+	-
ID3 C4.5 C5 CART J48 (C4.8) CHAID	- Construção simples e rápida - Problemas com muitas dimensões - Fácil representação e visualização (simbólico) - Facilmente convertida em regras	Necessário muitos dados para descobrir estruturas complexas

Aprendizagem Automática – Redes Neuronais Artificiais



[MultiLayer Perceptron]

	+	-
Backpropagation	Problemas cujos dados são complexos incompletos ou com ruído	- Dificuldade em trabalhar com variáveis categóricas com muitos valores associados - Tempo de treino - Difícil representação e visualização

1. Inicializar aleatoriamente os pesos da rede $W \in [-0.1, 0.1]$
2. Escolher um par de entrada-saída:
 x_i - vector de entrada
 y_i - vector de saída
3. Propagar as ativações desde a camada de entrada até à camada de saída usando a função de ativação SIGMOIDE ($x_i \rightarrow h_i \rightarrow o_i \rightarrow y_i$)
4. Calcular os erros das unidades na camada de saída, de seguida para a(s) camada(s) intermédia(s)
 $\sigma 2_j = o_j(1 - o_j)(y_j - o_j) \quad j=1, \dots, C$
 $\sigma 1_j = h_j(1 - h_j) \sum_{i=1 \dots C} \sigma 2_j \cdot W 2_{ji} \quad j=1, \dots, B$
5. Ajustar os pesos desde a última camada escondida até à camada de entrada
 $\Delta W 2_{ij} = \eta \cdot \sigma 2_j \cdot h_i \quad i=0, \dots, B \quad j=1, \dots, C$
 $\Delta W 1_{ij} = \eta \cdot \sigma 1_j \cdot x_i \quad i=0, \dots, A \quad j=1, \dots, B$
 (η - taxa de aprendizagem (0.35) é um bom valor)
6. Voltar ao passo 2. Quando todos os pares de entrada-saída do conjunto de treino estiverem processados passou-se uma ÉPOCA.
7. Repetir os passos 2..6 durante as épocas desejadas.

[Retropropagação]

Aprendizagem Automática – Modelos de Bayes

Probabilidade da entrada ser X se a saída for H

Probabilidade associada à saída H

$$P(H | X) = \frac{P(X | H)P(H)}{P(X)}$$

Probabilidade da saída ser H quando a entrada é X

Probabilidade associada à entrada X

[Teorema de Bayes]

	+	-
Naive Bayes Gaussian Multinomial	▪ Descrição do conhecimento sem a necessidade de todas as combinações possíveis ▪ Representação e visualização relativamente difícil	▪ Representação das dependências e independências entre as variáveis

Naive Bayes

Pressuposto de que as variáveis não interagem entre si

A representação do modelo corresponde a uma lista de probabilidades:


Probabilidades das classes – probabilidade de cada classe

Probabilidades condicionadas – probabilidade condicionada de cada valor das variáveis da entrada dada para cada valor das classes


Aprendizagem Automática – Máquinas Vetor de Suporte

Cada valor das n variáveis de entrada é representado num espaço de n dimensões

Objetivo – definir os hiperplanos que separam melhor as classes maximizando a margem



[Separador linear]




+			-		
Kernel Linear					
Kernel Não-linear (Polinomial, Gaussiano, Sigmoidal)					
▪ Outliers			▪ Sensível ao ruído		
▪ 2 classes – extensões para multi-classe			▪ Tempo de treino		
▪ Grandes espaços dimensionais			▪ Interpretação do modelo		
▪ Nº dimensões > nº exemplos			▪ Não providenciam diretamente estimativas de probabilidades da saída		
▪ Utiliza apenas um subconjunto dos pontos do conjunto de treino (vetores de suporte)			▪ Difícil representação e visualização		

Aprendizagem Automática – Random Forest

É uma equipa colaborativa de árvores de decisão que trabalham juntas para fornecer um resultado único resultado

Algoritmo RF


- 1 - Ensemble of Decision Trees
- 2 - Random Feature Selection
- 3 - Bootstrap Aggregating or Bagging
- 4 - Decision Making and Voting



+			-		
Gini Index			▪ Addressing Overfitting		
Gain Ratio			▪ Optimizing Computational Resources		
Information gain			▪ Dealing with imbalanced data		
...			▪ Defining complex models		
▪ High Predictive Accuracy			▪ Handling noisy data		
▪ Resistance to Overfitting			▪ Managing Memory Usage		
▪ Large Datasets Handling					
▪ Variable Importance Assessment					
▪ Built-in Cross-Validation					
▪ Handling Missing Values					
▪ Parallelization for Speed					

Aprendizagem Automática – Deep Learning

São redes neurais que possuem múltiplas camadas de nós interconectados. Essas redes podem aprender representações complexas de dados descobrindo padrões e recursos hierárquicos nos dados.



Aplicações

Computer vision

- Object detection and recognition

- Image classification

- Image segmentation

Natural language processing (NLP)

- Automatic Text Generation

- Language translation

- Sentiment analysis

- Speech recognition

Reinforcement learning


- Game playing

- Robotics

- Control systems

+			-		
Feedforward neural networks (FNNs)			High accuracy		
Convolutional Neural Networks (CNNs)			Automated feature engineering		
Convolutional Recurrent Neural Networks (RNNs)			Scalability		
			Flexibility		
			Continual improvement (incremental learning)		
			High computational requirements		
			Interpretability		
			Overfitting		
			Black-box nature		

Aprendizagem Automática – Sistemas de Classificadores



1 $[1,1,1,1,\#, \#,1,\#,1,1,1,1,1,\#, \#,0,1,\#, \#]===>$

$[0,1]::[463.83,0.65]$

2 $[0,1,1,1,\#, \#,1,\#,1,1,1,1,1,\#, \#,0,1,\#, \#]===>$

$[0,1]::[353.52,0.7]$

[Classificadores]

1. Iniciar o sistema
 $t = 1$
Criar aleatoriamente um conjunto de classificadores
2. Detecção (percepção)
3. Unificação
4. Licitação (ativar classificadores vencedores)
5. Selecionar na lista de mensagens aquelas que se destinam ao ambiente
6. Distribuição de créditos
7. Coleta de taxas
8. Resolução de conflitos
9. Repercussão (atuação)
10. Colocar o estado de todos os classificadores em não ativo
11. Algoritmo genético (segundo critério de execução)
12. Incrementar o ciclo de tempo
 $t = t + 1$
13. Repetir a partir do passo 2 até atingir condição de paragem

	+	-
XCS, UCS	- Problemas que envolvem a melhoria de soluções - Problemas não-lineares - Capacidade inventiva - Aprendizagem on-line - Representação e visualização relativamente fácil	Grande número de avaliações para boas soluções