

Mestrado em Engenharia e Ciência de Dados
Visualização de Dados e Informação

Ficha de exercícios 2 – Exploração e visualização de dados tabulares

1. Pretende-se analisar, explorar e visualizar o dataset “titanic.csv”, disponível na BlackBoard (retirado da fonte <https://www.kaggle.com/c/titanic/>).
 - a. Abstração de dados → inspecione o arquivo csv e responda às seguintes questões:
 - i. Qual é o tipo do dataset?
 - ii. Quantos atributos tem?
 - iii. De que tipo são os atributos (cada um deles)?
 - iv. O que significa cada um deles (consultar fonte, se necessário)?
 - v. Quantos itens tem dataset?
 - b. Faça o seguinte conjunto de testes recorrendo à linguagem de programação Python e à biblioteca Pandas.

```
import pandas as pd  
  
df = pd.read_csv("titanic.csv")  
  
print(df.head())  
print(df.info())  
print(df.shape)  
print(df.describe())  
print(df.info())
```

- i. Interprete as saídas apresentadas pela consola e compare os resultados (que fizerem sentido comparar) com as respostas dadas na alínea anterior.
- ii. Teste a seguinte linha e comente o que vê:

```
print(df['Survived'].value_counts())
```

iii. Verifique os resultados que surtem as seguintes linhas:

```
mulheres_1classe = df[(df['Sex'] == 'female') & (df['Pclass'] == 1)]
print(mulheres_1classe.head())
subset = mulheres_1classe[['Sex', 'Age', 'Pclass', 'Survived']]
print(subset.head())
```

Comente o que faz a primeira linha do excerto e quais as diferenças entre essa mesma linha e a quarta 3ª linha?

iv. Agora, crie gráficos recorrendo às seguintes linhas de código:

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.barplot(x='Sex', y='Survived', data=df)
plt.title("Taxa de sobrevivência por gênero")
plt.show()
```

Comente o resultado.

v. Acrescente as seguintes linhas e código:

```
sns.histplot(data=df, x='Age', hue='Survived', kde=True, multiple='layer')
plt.title("Distribuição de idades vs sobrevivência")
plt.show()
```

Descreva o que vê. Qual o tipo de distribuição das idades das pessoas que estariam no Titanic? Em que faixas etárias se notou uma maior taxa de sobrevivência? E a menor?

vi. Altere o gráfico anterior para analisar o impacto da mortalidade/sobrevivência nas diferentes classes em que viajavam os passageiros.

2. Agora, analise, explore e visualize o dataset "studentsperformance.csv", disponível na BlackBoard (retirado da fonte <https://www.kaggle.com/datasets/spscientist/students-performance-in-exams/>).

a. Abstração de dados → inspecione o arquivo csv e responda às seguintes questões:

- Qual é o tipo do dataset?
- Quantos atributos tem?

- iii. De que tipo são os atributos (cada um deles)?
- iv. O que significa cada um deles (consultar fonte, se necessário)?
- v. Quantos itens tem dataset?

Nota: antes das próximas alíneas, adicione a seguinte linha ao seu código:

```
df.columns = [c.replace(" ", "_").lower() for c in df.columns]
```

- b. Teste as seguintes linhas de código:

```
bins = [0, 25, 50, 75, 100]
labels = ["0-25", "25-50", "50-75", "75-100"]

df['math_range'] = pd.cut(df['math_score'], bins=bins, labels=labels, include_lowest=True)
df['reading_range'] = pd.cut(df['reading_score'], bins=bins, labels=labels, include_lowest=True)
df['writing_range'] = pd.cut(df['writing_score'], bins=bins, labels=labels, include_lowest=True)

cont_lunch = df.groupby(['Lunch', 'math_range']).size().unstack(fill_value=0)
print("Contagens por tipo de almoço e intervalo de notas (Matemática):")
print(cont_lunch)
```

- c. Ajuste o código cedido em b. para:
- i. análise de distribuição das notas a matemática por género;
 - ii. análise de distribuição das notas a matemática por curso de preparação (*test_preparation_course*);
- d. Repita o processo subjacente às linhas b. e c. para analisar as mesmas distribuições, mas por competências de escrita (*writing_score*) e leitura (*reading_score*).
- e. Teste e comente o seguinte excerto de código:

```
import matplotlib.pyplot as plt

#...

bins = [0, 25, 50, 75, 100]
labels = ["0-25", "25-50", "50-75", "75-100"]

df['math_range'] = pd.cut(df['math_score'], bins=bins, labels=labels, include_lowest=True)
df['reading_range'] = pd.cut(df['reading_score'], bins=bins, labels=labels, include_lowest=True)
df['writing_range'] = pd.cut(df['writing_score'], bins=bins, labels=labels, include_lowest=True)

contagens = pd.DataFrame({
    'Matemática': df['math_range'].value_counts().reindex(labels, fill_value=0),
    'Leitura': df['reading_range'].value_counts().reindex(labels, fill_value=0),
    'Escrita': df['writing_range'].value_counts().reindex(labels, fill_value=0)
})

contagens.plot(kind='bar', figsize=(8,5))
plt.title("Distribuição de notas por intervalo e disciplina")
plt.xlabel("Intervalo de notas")
plt.ylabel("Número de alunos")
plt.legend(title="Disciplina")
plt.xticks(rotation=0)
plt.show()
```

Comente os resultados dos gráficos resultantes.