

Mestrado em Engenharia e Ciência de Dados


Visualização de Dados e Informação

Ficha de exercícios 5 – Gráficos de dispersão, regressão e heatmaps

Nota: todo o código estará disponível na BlackBoard, mas de forma indiscriminada, para que o aluno possa interpretar os trechos e usá-los nos exercícios com base no seu entendimento. Por vezes, é necessário prestar atenção ao código comentado.


1. Admita que um conjunto de apostadores profissionais pretende estudar o perfil de um conjunto de maratonistas para perceber como e em que atletas apostar. Para isso, irão explorar e visualizar os maratonistas da corrida de Boston de 2019 (retirado de <https://github.com/adrian3/Boston-Marathon-Data-Project/blob/master/results2019.csv> e disponibilizado na BlackBoard com o nome “*boston_results_2019.csv*”).
 - a. Carregue o csv com Pandas (com a flag *on_bad_lines="skip"* para ignorar itens mal formatados), filtre o género (“gender”) por masculino (“M”) e gere o gráfico de dispersão combinando tempos de término da prova com as idades dos atletas.

Resultado esperado:




- b. Elimine *outliers* com o método do intervalo interquartil.

Resultado esperado (se fizer a visualização do gráfico após remoção de *outliers*):



- c. Determine, manualmente, a linha que melhor se ajusta aos dados, procurando perceber a qualidade desse ajuste via R^2 e RMSE.

Resultados esperados:



```
m (inclinação) = 85.8210
b (interceção) = 9397.2192
R^2              = 0.1557
RMSE (min)      = 2319.75
```

- d. Agora, experimente configurar a visualização do gráfico com o seguinte código:

```
plt.figure(figsize=(8, 5))
sns.regplot(
    data=df_m,
    x="age",
    y="official_time_min",
    scatter_kws={'alpha': 0.35},
    line_kws={'color': 'red', 'linewidth': 2},
    ci=None # remove intervalo de confiança
)

plt.title("Boston Marathon 2019 (M) – Tempo vs Idade (com linha de regressão)")
plt.xlabel("Idade (anos)")
plt.ylabel("Tempo oficial (minutos)")
plt.grid(True)
plt.tight_layout()
plt.show()
```

Que resultado produziu o trecho?

- e. Experimente usar a equação reduzida da reta obtida para realizar algumas previsões com base em diferentes idades, no sentido de obter os respetivos tempos estimados para a conclusão da prova.
- f. Investigue outras combinações (por exemplo, género feminino, atletas até aos 35 anos, entre outros), para indicar aos apostadores qual é a que poderá gerar mais confiança nas apostas.

Relembre:

- Pelo quociente de Pearson (r^2 para distribuições lineares)
 - Varia entre -1 (correlação negative perfeita) e 1 (correlação positiva perfeita)

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

- Root mean square error (RMSE) → Raiz do erro quadrado médio
 - Quanto menor, melhor!

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

2. Admita que se pretende visualizar o perfil de remate de um conjunto de jogadores, considerando a seguinte distribuição de zonas da baliza.



Para isso, descarregue o ficheiro “penalty_shots_events.csv” que se encontra na BlackBoard. **Nota:** o dataset foi gerado com recurso a métodos de aleatoriedade computacional, pelo que não reflete dados reais.

- Leia o ficheiro e gere um *heatmap* configurado de forma consonante com a figura acima para os remates do Messi.

Código de apoio:

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv("penalty_shots_events.csv")

zonas = [
    "CSE", "CeS", "CSD",
    "CME", "CeM", "CMD",
    "CIE", "CeI", "CID"
]

agg = (
    df.groupby(["player", "zone"])
      .size()
      .reset_index(name="shots")
)

agg["shots_pct_player"] = agg.groupby("player")["shots"].transform(lambda s: 100 * s / s.sum())


def plot_heatmap_player(player_name, value_col="shots", cmap="YlOrRd"):
    base = pd.DataFrame({"zone": zonas})
    sub = agg[agg["player"] == player_name][["zone", value_col]]
    sub = base.merge(sub, on="zone", how="left").fillna({value_col: 0})

    mat = sub[value_col].to_numpy().reshape(3, 3)

    plt.figure(figsize=(4.5, 4))
    ax = sns.heatmap(
        mat,
        annot=True,
        fmt=".0f" if value_col == "shots" else ".1f",
        cmap=cmap,
        cbar=True,
        square=True,
        linewidths=.5
    )
    ax.set_title(f"Heatmap - {player_name} ({'Contagens' if value_col=='shots' else '% por jogador'})")
    ax.set_xticks([]); ax.set_yticks([])
    plt.tight_layout()
    plt.show()

plot_heatmap_player("Messi", value_col="shots")
```

Resultado esperado:



Para resolver os exercícios seguintes, recorra aos exemplos dados nas aulas e/ou a um serviço de inteligência artificial generativa da sua preferência.

- Da mesma forma, trace os perfis de remate dos jogadores do FC Porto, consolidando-os em mapa de calor.
- Gere um global, considerando todos os jogadores da amostra.
- Procure, destaque e explore outros datasets desportivos em que o heatmap possa fazer a diferença para algum decisor.